

## Obligatorisk innlevering 2 i STAT110

- Basert på kapittel 1-5 i boken.
  - Alle svar skal begrunnes, og det skal være med så mye mellomregning at fremgangsmåten fremgår tydelig av besvarelsen.
  - Noen oppgaver er basert på en tidligere eksamensoppgave. Hvis du trenger hjelp kan du kikke på disse, men merk at eksamensoppgavene **er endret**.
1. **Kvantedatamaskiner** Kvanteteknologi blir stadig viktigere og UiB opprettet i 2026 et eget senter for kvanteforskning: UiB Kvante. I stedet for “bits” som man finner i vanlige datamaskin har kvantedatamaskiner såkalte “qubits” som kan ta verdien 0 og 1 samtidig. Når du leser av en qubit får du imidlertid ut bare en av verdiene: 0 med sannsynlighet  $\alpha$  og 1 med sannsynlighet  $1 - \alpha$ , der  $\alpha \in [0, 1]$  er tall som den som programmerer maskinen velger. Denne oppgaven gir en svært forenklet fremstilling av kvanteteknologi. Vi illustrere det som er det store praktiske problemet med dagens kvantedatamaskiner, nemlig støy. Vi ser på en maskin som har 2 qubits.
- I en feilfri kvantedatamaskin (ingen støy) kan vi koble to qubits sammen i en såkalt *Bell-tilstand*. Dette betyr at de er maksimalt sammenkoblet. Hvis vi måler dem, vil de alltid gi samme verdi: enten blir begge 0, eller så blir begge 1. Det er helt umulig at den ene blir 0 og den andre 1. I den virkelige verden vil imidlertid **støy** (varmestråling, magnetfelt etc.) forstyrre systemet. Støyen gjør at en qubit kan flippe (endre verdi) ved et uhell, noe som ødelegger den perfekte sammenkoblingen.
- La  $X$  være resultatet av målingen av qubit 1, og  $Y$  være resultatet av målingen av qubit 2. Begge variablene kan ta verdiene 0 eller 1. I et eksperiment med en reell kvantedatamaskin blir systemet utsatt for støy. Den simultane sannsynlighetsfunksjonen  $P(X = x, Y = y)$  er gitt ved tabellen under:
- |         | $Y = 0$ | $Y = 1$ |
|---------|---------|---------|
| $X = 0$ | 0.42    | 0.08    |
| $X = 1$ | 0.08    | 0.42    |
- (a) Vis at tabellen representerer en gyldig simultan sannsynlighetsfordeling.
- (b) Finn marginalfordelingene til  $X$  og  $Y$ . Hva er sannsynligheten for at qubit 1 måles til å være 0?
- (c) Er kvantevariablene  $X$  og  $Y$  statistisk uavhengige? Begrunn svaret matematisk.
- (d) Hvor stor er sannsynligheten for at kvantedatamaskinen gjør en “feil” (det vil si at qubitene gir ulike svar,  $X \neq Y$ )?
- (e) Hvordan ville den simultane sannsynlighetsfordelingen sett ut dersom kvantedatamaskinen var helt perfekt (0 % støy), og med de samme marginalfordelingene? Sett opp en ny tabell for dette tilfellet.
2. **Inntektsfordeling i befolkningen** (Modifisert eksamen Juni 2021, oppg. 2a)

Vi ser på inntekt  $x$  (målt i millioner) i en befolkning. Tabellen under viser inntektsfordelingen for et utvalg på  $n = 13000$  personer.

Tabellforklaring:

- Kolonnen til venstre (uten navn) viser inntekt (i millioner) som et intervall (fra,til].
- Midtp.: Midtpunktet i inntektsintervallet. Eksempel: intervallet  $(0.0, 0.1]$  har midtpunkt 0.05.
- Frek: absolutt frekvens. Kolonnesum = 13000.
- Kumulativ viser kumulativ frekvens dvs. antall observasjoner som er mindre enn eller lik den aktuelle  $x$ -verdien (f.eks.  $1608 = 17 + 366 + 1225$ ).

|           | Midtp. | Frek | Kumulativ |
|-----------|--------|------|-----------|
| (0.0,0.1] | 0.05   | 17   | 17        |
| (0.1,0.2] | 0.15   | 366  | 383       |
| (0.2,0.3] | 0.25   | 1225 | 1608      |
| (0.3,0.4] | 0.35   | 2076 | 3684      |
| (0.4,0.5] | 0.45   | 2396 | 6080      |
| (0.5,0.6] | 0.55   | 2134 | 8214      |
| (0.6,0.7] | 0.65   | 1777 | 9991      |
| (0.7,0.8] | 0.75   | 1163 | 11154     |
| (0.8,0.9] | 0.85   | 772  | 11926     |
| (0.9,1.0] | 0.95   | 501  | 12427     |
| (1.0,1.1] | 1.05   | 279  | 12706     |
| (1.1,1.2] | 1.15   | 159  | 12865     |
| (1.2,1.3] | 1.25   | 58   | 12923     |
| (1.3,1.4] | 1.35   | 36   | 12959     |
| (1.4,1.5] | 1.45   | 20   | 12979     |
| (1.5,1.6] | 1.55   | 7    | 12986     |
| (1.6,1.7] | 1.65   | 8    | 12994     |
| (1.7,1.8] | 1.75   | 3    | 12997     |
| (1.8,1.9] | 1.85   | 0    | 12997     |
| (1.9,2.0] | 1.95   | 3    | 13000     |

- (a) Hvor stor andel av befolkningen tjener mindre eller lik 1 million? Hva er gjennomsnittsinntekt blant de som tjener mer enn 1.5 millioner (1.5 ikke inkludert)? (Her kan du bruke midtpunktet i intervallene i utregningen)
- (b) Hvis vi lager et histogram med tetthetsskala på  $y$ -aksen, hva er verdien (høyden) av histogrammet i intervallet  $(1.1, 1.4]$ ?

3. **Simultanfordeling** (Modifisert eksamen Høst 2018, oppg. 2)

Vi betrakter to tilfeldige variable  $X$  og  $Y$  med simultan sannsynlighetsfordeling  $p(x, y) = P(X=x \cap Y=y)$  gitt ved denne tabellen:

| $x \backslash y$ | 0    | 1    | 2    |
|------------------|------|------|------|
| 0                | 0.1  | 0.2  | 0.05 |
| 1                | 0.11 | 0.12 | 0.17 |
| 2                | 0.11 | 0.06 | 0.08 |

- (a) Finn de marginale sannsynlighetsfordelingene for  $X$  og  $Y$ . Hva er  $P(X=2|Y=2)$ ? Er  $X$  og  $Y$  uavhengige tilfeldige variable? Begrunn svaret.
- (b) Finn korrelasjonen mellom  $X$  og  $Y$  når du får vite at forventningene er  $E(X) = 0.9$  og  $E(Y) = 0.98$ , og variansene  $V(X) = 0.59$  og  $V(Y) = 0.62$ .
- (c) Finn betinget forventning  $E(Y|X=2)$  og betinget varians  $V(Y|X=2)$ .

4. **Investeringer** (ikke ekte tall)

En finansanalytiker har kommet frem til at Orkla (ORK), en aksje på Oslo Børs, har forventet avkastning  $E(X) = 8\%$  og varians til avkastningen lik  $V(X) = 0.36$ , mens Norsk Hydro (NHY), en annen aksje, har forventet avkastning  $E(Y) = 6\%$  og varians  $V(Y) = 0.49$ . Korrelasjonen mellom disse to aksjenes avkastning er  $\rho(X, Y) = 0.2$ . Finansanalytikeren vil investere en andel  $q$  ( $0 < q < 1$ ) i Orkla-aksjer og resten  $(1 - q)$  i Hydroaksjer. Den kombinerte investeringen har derfor avkastning:

$$U = qX + (1 - q)Y.$$

- (a) Sett  $q = 0.3$  slik at  $U = 0.3X + 0.7Y$ . Regn ut forventning og varians til  $U$ . Hvordan er disse i forhold til forventning og varians til hver av  $X$  og  $Y$ ?

Hint: Se på slides fra kapittel 5.3, og spesielt formelen for  $V(\sum_{i=1}^n a_i X_i)$ .

## 5. QR-koder



Figure 1: QR-kode fotografert i dårlig belysning, slik at kan være vanskelig å skille sorte og hvite piksler. Gråfargen ( $X$ ) i hvert piksel er derfor kodet på en skala fra 0 (hvit) til 100 (sort). Det sanne pikselverdien (uten skygge) er kodet  $Y = 0$  for hvit, og  $Y = 1$  for sort.

Start med å lese teksten under Figur 1. Vi skal generelt betrakte  $X$  og  $Y$  som tilfeldige variabler. For den uthevede pikselen i figuren er gråfargen  $X = 25$  og den sanne pikselverdien hvit, dvs.  $Y = 0$ . Vi antar at QR-koder er laget slik at det i gjennomsnitt er like mange hvite som sorte piksler, som betyr at  $p_Y(0) = p_Y(1) = 1/2$ .

I denne situasjonen er  $X$  kontinuerlig fordelt ( $0 \leq X \leq 100$ ) og  $Y$  er diskret fordelt, men vi kan likevel snakke om simultanfordelingen til  $X$  og  $Y$ . Vi starter ut med å definere betinget tetthet til  $X$ , gitt verdien til  $Y$ :

$$\begin{aligned} f_{X|Y}(x|0) &= \frac{6}{100} \left(1 - \frac{x}{100}\right)^5 && \text{(piksel egentlig hvit)} \\ f_{X|Y}(x|1) &= \frac{6}{100} \left(\frac{x}{100}\right)^5 && \text{(piksel egentlig sort)} \end{aligned}$$

- (a) Lag et plott av marginaltettheten  $f_X(x) = \sum_y f_{X|Y}(x|y)p_Y(y)$  for  $0 \leq x \leq 100$ .

Bayes formel tar i denne situasjonen formen:

$$P(Y = 0|X = x) = \frac{f_{X|Y}(x|0)p_Y(0)}{f_X(x)}$$

- (b) Bruk Bayes formel til å finne sannsynligheten for hvit når  $x = 25$  slik som på figuren.

## 6. Chatbot

Chatbot'er (av typen ChatGPT) ser på det forrige ordet i setningen, eller de  $N - 1$  foregående ordene (N-gram modeller), når neste ord skal genereres. Vi skal her se på en veldig forenklet chatbot som vi kaller CHAT110. Den bruker følgende algoritme med 3 steg til å generere en setning:

1. CHAT110 starter en setning med å trekke et ord tilfeldig fra vokabularet sitt i henhold til sannsynligheter:

| jeg  | du   | heter | kjenner | Hans | Ole  | . |
|------|------|-------|---------|------|------|---|
| 0.22 | 0.15 | 0.18  | 0.22    | 0.17 | 0.06 | 0 |

Den kjenner altså kun seks ord i tillegg til punktum.

2. CHAT110 trekker neste ord med betingende sannsynligheter fra følgende tabell:

|             |         | Neste ord |     |       |         |      |      |      |
|-------------|---------|-----------|-----|-------|---------|------|------|------|
|             |         | jeg       | du  | heter | kjenner | Hans | Ole  | .    |
| Forrige ord | jeg     | 0         | 0   | 0.64  | 0.36    | 0    | 0    | 0    |
|             | du      | 0         | 0   | 0.45  | 0.25    | 0.18 | 0.12 | 0    |
|             | heter   | 0         | 0   | 0     | 0       | 0.38 | 0.46 | 0.16 |
|             | kjenner | 0         | 0.3 | 0     | 0       | 0.23 | 0.3  | 0.17 |
|             | Hans    | 0         | 0   | 0.28  | 0.32    | 0    | 0.15 | 0.25 |
|             | Ole     | 0         | 0   | 0.35  | 0.3     | 0.2  | 0    | 0.15 |

3. CHAT110 bygger setningen inntil den trekker et punktum. Da er setningen ferdig.

**Eksempel** Sannsynligheten for at CHAT110 kommer til å generere akkurat setningen 'jeg heter Hans.' er:  $P(\text{jeg}) \times P(\text{heter}|\text{jeg}) \times P(\text{Hans}|\text{heter}) \times P(.\text{Hans}) = 0.22 \times 0.64 \times 0.38 \times 0.25 = 0.013376$ . (Svaret kan godt rundes av.)

- (a) Hva er sannsynligheten for setningen 'kjenner du Hans Ole.'? Skriv opp løsningen på samme måte som i eksempelet over.
- (b) Hva er sannsynligheten for at setningen består av kun ett ord (i tillegg til punktum)?

## 7. Maxwell-Boltzmann-fordelingen

Molekyler i en gass er i bevegelse, men hastigheten ( $x$ ) er ikke den samme for alle molekylene. Den varierer i henhold til Maxwell-Boltzmann-fordelingen som har tetthet

$$f(x; a) = \sqrt{\frac{2}{\pi}} \frac{x^2 e^{-\frac{x^2}{2a^2}}}{a^3},$$

hvor  $a = \sqrt{\frac{kT}{m}}$  er parameteren i fordelingen, der:

- $m$  er massen til molekylet
- $k$  er Boltzmanns konstant ( $1.38 \times 10^{-23}$  J/K)
- $T$  er temperaturen målt i Kelvin

Du finner informasjon som du vil trenge om fordelingen på Wikipedia (klikkbar lenke).

- (a) Beregn forventet hastighet  $E(X)$  og varians  $V(X)$  til et tilfeldig valgt molekyl i en hydrogengass ( $m = 3.34 \times 10^{-27}$  kg) ved temperatur  $T = 273.15$  K (0 grader Celsius).




Figure 2: CDF (kumulativ fordelingsfunksjon) for  $X$  for tre ulike verdier av  $a$ .

- (b) Man bruker ofte CV (“coefficient of variation”) som mål på hvor stor usikkerheten er i forhold til forventet verdi. Vi definerer  $CV = SD(X)/E(X)$ , der  $SD$  er standardavvik. Regn ut  $CV$  med tallene fra spørsmål (a). Hva skjer  $CV$  når vi varierer  $T$ ? Begrunn svaret.

Nå ser vi ikke lenger på  $m = 3.34 \times 10^{-27}$  kg og  $T = 273.15$  K.

- (c) Hva er medianen til  $X$  når du leser av (ca.) i Figur 2 for hver av de tre verdiene av  $a$ ? Øker eller avtar medianen som funksjon av  $a$ ? Sammenlikn median og forventning for de tre verdiene av  $a$  som er brukt i Figur 2. Hva skyldes eventuelle forskjeller mellom de to målene på sentrum i fordelingen?

Tenk deg at det finnes et apparat som kan måle eksakt hastighet for enkeltmolekylder i en gass. (Et slikt apparat finnes trolig ikke). En kjemiker måler hastigheten til  $n = 10000$  tilfeldig valgte molekyler. Hun vet at mange statistiske metoder krever at data er normalfordelt, hvilket ikke er forenlig med Maxwell–Boltzmann-fordelingen. I et håp om å bringe data nærmere en normalfordeling tar hun naturlig logaritme av målingene.

- (d) Bruk plottene i Figur 3 til å diskutere hvordan data avviker fra en normalfordeling (både før og etter hun har tatt logaritme). Bringer logaritmen oss nærmere en normalfordeling?





Figure 3: Histogram av 10000 målinger av molekylhastigheten i en gass før (venstre) og etter (høyre) at vi har tatt logaritmen av målingene. Øverste rekke viser histogram, mens nederste rekke viser normalplott. Den rette linjen er slik normalplottet skulle sett ut dersom data hadde vært normalfordelt.

## 8. Sannsynlighetsbegrepet i praksis



Figur 4: Pepe Silvia / Charlie-memet med konspirasjonstavle (*It's Always Sunny in Philadelphia*), tekstlagt for Grimes (2016).

Virkeligheten er sjelden like ryddig som i læreboka. I mediene hører man gjerne påstander om at noe er “helt sikkert” eller “helt utrolig”. Det er vurderinger av sannsynligheten for en hendelse, ofte løsrevet fra faktiske analyser av hendelser.

Poenget er ikke å finne “fasit”, men å merke usikkerheten når sannsynligheter kastes rundt uten at begrepet er avklart.

I Grimes (2016) estimeres sannsynligheten for en “lekkasje” i konspirasjoner med mange involverte til

$$p \approx 4 \cdot 10^{-6} \text{ per person per år.}$$

Med “lekkasje” menes at avslørende informasjon er på avveie — ikke at konspirasjonen nødvendigvis er avslørt.

Beskriv med egne ord (20–100) hvordan denne  $p$ -en passer med sannsynlighetsbegrepet i STAT110.

*Hint:* Tenk utfallsrom og eksperiment.